

融合主观不相似度知识的焊接声熔透状态识别方法

背景：焊接声音信号与主观感知知识

在电弧焊接过程中，有经验的焊工能够通过声音变化来判断熔透状态。这种能力源于人耳对焊接电弧声“音色”变化的敏锐感知。例如，不同熔透状态下，电弧的声压级、频谱分布和稳定性都有差异¹。传统的熔透监测方法往往直接依赖物理信号特征或时频图像输入深度模型，但缺乏对“焊工主观听感”的建模²。因此，如何将焊工凭听觉经验形成的主观知识融入模型，使深度学习同时由数据和知识双驱动，是一项创新性研究方向。

主观不相似度矩阵正是对这类经验知识的量化表达。通过听觉心理实验，研究者可以请多名焊接专家对若干段电弧声音两两打分，评价其感知相似程度，从而构建一个**主观不相似度矩阵**（矩阵元素表示任意两段声音在听觉上有多不同）³。该矩阵体现了人耳对声音信号差异的主观判断。例如，如果两段声音在人耳听来熔透状态相近，则矩阵中对应元素的不相似度值低；反之则高。这种矩阵提供了客观信号之外的**主观经验先验**。

然而，深度神经网络擅长从大数据中学习模式，对人为经验缺乏直接利用机制。将上述主观不相似度信息融入深度模型，有望构建**数据驱动 + 知识驱动**的融合框架，提高模型对熔透状态的识别性能和鲁棒性⁴。下面将从三个方面探讨如何融合主观不相似度矩阵，以及在此基础上提出一个融合主观知识与声学数据的模型方案。

方法一：构建感知嵌入空间作为输入特征

思路： 利用主观不相似度矩阵，通过多维尺度分析（MDS）或类似的嵌入方法，将每段声音映射到一个低维“感知空间”中。这个空间的坐标即为反映人耳感知的**主观嵌入特征**，可作为模型的额外输入特征。

实现步骤： 对收集到的主观不相似度矩阵执行MDS算法，得到每条声音样本在低维（例如2维或3维）空间中的坐标。MDS尝试让低维点之间的欧氏距离尽可能匹配原始人类不相似度⁵。在实际研究中发现，仅用2维就能近乎完美地重构焊接声样本间的主观不相似关系（压力值 ≈ 0 ）⁶。这表明人耳听觉“音色空间”可能是低维且结构上接近欧氏的⁶。因此，选取2~3维的感知嵌入既能涵盖主要的人感知差异，又避免高维嵌入引入噪声。

接下来，将得到的每个样本的感知嵌入坐标作为特征之一，与传统声学特征或深度特征一起输入模型。例如，可以为每条声音样本形成一个**多源特征向量**：包含时间域特征（如RMS能量、过零率等）、频域特征（如频谱质心、频带能量比等）以及**MDS感知坐标**⁷⁸。在模型设计上，可以将这些特征直接拼接输入一个分类器（如多层感知机、SVM等），或者在深度网络中将感知坐标作为并行通道输入与声学信号融合。

优点： 感知嵌入特征引入了焊工经验所反映的“音色距离”信息，能辅助模型在特征空间上拉近人耳认为相似的样本、区分人耳认为差异大的样本。这种显式融合主观和客观特征的方法已被证明有效：相比仅用客观特征的模型，加入MDS感知坐标的多源特征方案在极端噪声条件下的分类宏F1分数显著提升⁹。这说明在人耳判别维度上，相似的声音即使被噪声掩盖，模型仍能依据嵌入特征将其归类，从而增强了鲁棒性。

注意事项： 需要确保感知嵌入维度适中、含义清晰。如果维度过高，可能掩盖物理特征作用¹⁰。此外，主观嵌入通常是基于少量典型样本计算的（例如文献中以15条声音样本构建嵌入³）。对于未参与MDS计算的新样本，可以考虑：

- **插值/外推：** 基于其客观特征，与已嵌入样本的距离来估计其感知坐标。例如，训练一个回归模型，用原始声学特征预测MDS坐标。

- **原位结合**：或在模型训练过程中，仅对有感知坐标的样本使用该特征，对于没有先验嵌入的新样本，可以暂不使用感知特征或使用模型渐进学习去推断。

总之，方法一通过**特征级融合**将人耳知识注入模型输入层，属于较直接的知识融合方式。

方法二：将不相似度用于监督信号或损失函数

思路：利用主观不相似度矩阵提供**附加的监督约束**，指导深度网络的内部表示或输出，使其与人类感知的一致性更高。换言之，引入一种**度量学习（metric learning）**策略，以人耳定义的“相似/不相似”关系来塑造模型的嵌入空间或判别边界。

实现途径：

- **定量匹配损失**：若不相似度矩阵提供了两个样本 i, j 间的定量差异 d_{ij} ，可以令模型学得一个映射 $f(\cdot)$ ，使得样本 i, j 输出表示间的距离 $\Delta_{ij} = |f(x_i) - f(x_j)|$ 与 d_{ij} 尽可能接近。可设计损失函数如：

$$\mathcal{L}_{\text{dist}} = \sum_{i < j} w_{ij} \big(|f(x_i) - f(x_j)| - d_{ij} \big)^2$$

其中 w_{ij} 是权重（例如所有对等权，或根据重要性设定）。该损失即要求**网络嵌入的Gram矩阵与主观不相似度矩阵尽量一致**¹¹。Saito等研究者在说话人嵌入任务中采用了类似思想，用大规模主观相似度评分构建矩阵，并最小化嵌入向量Gram矩阵与之的Frobenius范数差异，成功训练出与主观评分高度相关的说话人向量¹¹。这证明了通过矩阵级别的损失对网络表示施加全局约束的可行性。

• **对比/三元组损失**：若主观实验仅给出了“相似”或“不相似”的判断（或一个相对评分），可以采用**对比损失**或**三元组损失**等方式。比如，对任意样本对 (i, j) ：若其主观不相似度低（相似度高），则视为“正对”（网络应输出相近的嵌入）；若不相似度高，则视为“负对”（嵌入应疏远）。对比损失定义为：

$$\mathcal{L}_{\text{contrastive}} = y_{ij} |f(x_i) - f(x_j)|^2 + (1 - y_{ij}) \max(0, m - |f(x_i) - f(x_j)|)^2$$

其中 $y_{ij} = 0/1$ 表示一对样本是否应相似， m 是距离阈值¹²。三元组损失则构造三元组 (a, p, n) ，要求锚点 a 与正样本 p 距离比与负样本 n 距离小一定margin，即：

$$\mathcal{L}_{\text{triplet}} = \sum (|f(x_a) - f(x_p)|^2 - |f(x_a) - f(x_n)|^2 + \alpha)_+$$

这里 $(\cdot)_+$ 表示ReLU截断， α 是margin。正负样本的选取由主观相似关系决定，例如选择人耳感知上明显不同类别的声音作为 n 。

• **多任务或软标签监督**：另一种思路是将主观相似信息当作**辅助任务**。例如，设计网络的一个分支直接输出对输入声音的“感知嵌入坐标”或与若干参考声音的相似度评分，并用主观实验得到的值来监督该分支。在主干进行熔透分类的同时，辅助分支会预测人类感知结果。这相当于知识蒸馏或多任务学习，将人类的判断当作一种软标签提供给模型。训练时，总损失为分类交叉熵与感知回归损失之和（或加权）。通过这种方式，模型内部会调整参数来同时顾及准确分类和保持与人感知的一致。

预期效果：有了上述**主观相似度约束**，模型的隐藏表示将更贴近人类经验分类方式。例如，人耳觉得相近的未熔透与欠熔透声音，其深度特征距离也将被拉近；而过熔透（烧穿）与未熔透这类听感差异大的样本在嵌入空间中会被推得更远。这种经人类知识“校正”的特征空间，有望提高模型对边界模糊样本的判别能力，并降低对训练数据量的依赖。当数据量有限时，主观约束相当于一种**先验正则**，可防止模型学习到与人认知不符的无效模式。

实现要点：

- 需平衡主观损失与主任务损失的权重，避免过强的度量约束影响分类准确率。通常可先预训练或同步训练，视验证集效果调整权重。

- 若主观评分样本有限（如仅15对样本），全对儿约束可能数据不足。这种情况下，可借助**同类推断**扩充：假设属于同一熔透类别的声音在人耳理应更相似，则额外生成同类样本对作为正对。这种推理虽非直接实验所得，但符合一般经验，可增强约束的覆盖面。

- 在优化实现上，成对损失会增加计算开销。可采用**批次内采样**（batch-wise sampling）的方法，每个小批中随机抽取一定比例的样本对计算损失，而非全矩阵遍历。此外，利用高效矩阵运算或显存换算时间的方法计算成对距离，也能加速训练。

综上，方法二通过**损失函数级融合**，将主观知识融入模型训练目标，从而**塑造网络的表示空间**使之贴合人类感知。

方法三：构造基于不相似度的图结构或辅助分支

思路： 将主观不相似度视为定义样本之间关系的“邻接”，构建一个**样本关系图（graph）**，并将其融入网络结构或推理过程中。借助图论方法，利用人类知识定义的邻接关系对模型进行**先验约束**或**信息传播**。

实现途径：

- **图神经网络（GNN）融合：** 将所有声音样本看作图中的节点，两两节点间的边权重由主观相似度确定（相似度高则边权重重大，不相似则无边或权重低）。在训练过程中，可采用**图卷积网络（GCN）**或**图注意网络（GAT）**对样本特征进行传播和聚合¹³。具体而言，每个节点初始有其声学特征表示，GCN根据邻接矩阵计算各节点邻居的特征加权和，更新节点表示。一层图卷积的更新公式通常为：

$$H^{(l+1)} = \frac{1}{D} A H^{(l)} W^{(l)}$$

其中 A 是邻接矩阵（可由主观不相似度推导）， D 是度矩阵。通过这样的**消息传递机制**，感知上相似的样本将彼此影响，趋向于形成相近的表示或输出，从而使模型决策在图结构上**平滑**。这种思想与半监督学习中的图正则类似：鼓励连接在图上的样本输出相似的预测¹⁴。对于有标签的数据集，GCN可结合少量标注样本实现更准确的分类¹⁵；在我们的问题中，即使所有样本都有标签，图结构依然可以作为额外信息改善模型对复杂关系的建模。值得注意的是，如果采用GCN，需要将其整体纳入模型架构（训练时同时学习图卷积参数）。在推理阶段，如需对新样本预测，可将其暂时挂接到已有图中（例如根据声学特征计算其与图中参考节点的相似度形成新边），再通过图模型计算输出。

• **图先验正则：** 如果不使用显式图网络，也可在损失中加入**图拉普拉斯正则项**。例如：

$$L_{\text{graph}} = \lambda \sum_{i,j} A_{ij} |f(x_i) - f(x_j)|^2$$

其中 A_{ij} 可以由主观不相似度矩阵按某种方式转换（如 $A_{ij} = \exp(-d_{ij})$ 或归一化）。这个正则项鼓励在图上相连的样本具有相似的网络输出或特征，从而保持**感知相近→模型输出相近**的性质。

Graph Regularization被认为是一种灵活的技术，可以强制优化解满足图结构所描述的关系¹⁴。在本任务中，它会推动模型对感知相似的声音给出一致的熔透状态判断。该方法实现简单，通过在总损失中加上 L_{graph} 即可，无需改变原有网络结构。

• **基于图的辅助分支或注意力：** 主观相似关系还可用于设计**注意力机制**或**记忆网络**。比如，构建一个小型网络分支，以某种方式**访问其他样本的信息**：对每个输入声音，该分支根据其与所有参考声音的主观相似度，从一个“记忆库”中加权检索参考样本的特征或预测，然后融合进主分支的决策。这类似于在推理时参考“典型样本”的做法。如果一个未知声音与某参考声音在人耳上极为相似，模型就可加强参考样本所属类别的权重，提高判别可靠度。实现上，可以预先将若干典型声音（如那15个样本）通过主干网络编码成向量并存储。对于新输入，用注意力权重 α_j （由主观相似度或模型估计的相似度计算）加权求和这些存储向量，得到一个**经验先验向量**，再与当前输入的表示拼接用于分类。如此，模型相当于多看了一眼“与该声音听起来类似的已知熔透状态”的参考，从而利用了先验知识。

优势和创新点： 图结构或辅助分支的方法，将**知识融入模型结构本身**，而非仅作为数据或损失。相比传统单一模型，它能够表示更复杂的依赖关系。例如，通过图卷积，模型可以学习到**集体的声音模式**：某些声音簇聚在一起（对应某熔透状态），某些远离。这弥补了普通CNN只看单样本无法利用样本间关系的不足。在其他领域，类似思路已用于提升模型对少样本或噪声数据的性能，例如通过用户相似度图改进推荐系统鲁棒性等¹⁶。在焊接声领域，引入基于主观听感的关系图尚属新颖尝试，它将专家知识转化为模型可用的拓扑结构，是对端听听觉识别的有益补充。

挑战： 如果主观不相似度矩阵只涵盖少量样本，构建全局图的效果有限。这种情况下，可以考虑结合**数据驱动的相似度**一起构图：例如，两样本边权重取 $f_{\text{human}}(i,j)$ （人耳评分归一化值）和 $f_{\text{acoustic}}(i,j)$ （基于信号特征的相似度，如谱差异）加权得到。这样在缺乏人工评价的样本对上，仍可依据客观相似性构建图，从而扩充图的连通性。不过需确保权重选择合理，以免引入人耳并不认同的关系。

融合主观知识与声学数据的模型框架设计

综合以上方法，我们可以提出一个**融合主观感知知识与声学数据的熔透识别框架**。其核心思想是在深度模型中同时融合**感知特征、感知约束和感知关系**，实现知识与数据的双驱动。一个可能的框架包括如下模块：

- 声学特征提取与主观嵌入获取：** 对原始焊接声音进行预处理（降噪、截取等）后，提取多种声学特征。例如，计算传统时域和频域特征（RMS、过零率、频谱质心、频带能量等）以及梅尔频率倒谱系数等听觉相关特征⁷。同时，根据预先所得的主观不相似度矩阵，用MDS得到低维感知嵌入坐标，将其作为每个样本的“感知特征”。对于新样本，如没有嵌入，可通过训练好的映射模型预测其坐标，或仅在参考样本上使用嵌入特征。
- 深度网络主干：** 将声音信号转换为时频图像（如短时傅里叶变换谱图）或直接作为波形输入深度神经网络。可以采用卷积神经网络（CNN）提取时频结构特征¹⁷，¹⁸。事实上，已有研究成功地将焊接电弧声的时频图输入CNN，实现对熔透三种状态（未熔透、正常熔透、过熔透）的自动分类¹⁷ ¹⁹。我们可借鉴这些成熟的CNN架构（如VGG、ResNet变体等）来构建声学特征的深度提取主干。经过若干卷积和池化层，主干网络输出一个**深度嵌入向量**（在分类网络中通常是倒数第二层的隐藏表示）。
- 主观特征融合层：** 将上述深度嵌入与主观感知嵌入特征融合。一种简单做法是在**特征层直接拼接**：将CNN提取的向量与MDS感知坐标连接成更长的特征向量⁸。然后送入后续分类层。这相当于赋予网络一个“感知坐标系”的参考。在我们的框架中，还可以引入一个**图注意模块**：利用主观相似度矩阵构造的图，对深度嵌入做一次调整。例如，针对每个深度嵌入向量，计算它与其他参考样本向量的相似度分布（可采用人耳矩阵权重或学得注意力权重），再加权求和得到一个“感知邻居向量”，最后与原嵌入拼接或相加。这一步使得每个样本的表示结合了与其**主观近邻**的信息，从而在表示中显式包含了主观关系。
- 分类决策层：** 将融合了多源特征的最终表示输入一个分类器以判别熔透状态。可选用传统机器学习分类器（如支持向量机SVM、随机森林）或者直接在网络末端接全连接层+Softmax输出。此前的研究对比了多种分类器在该任务上的效果，例如RBF核SVM、MLP、CNN等²⁰。在融合感知特征的情况下，简单分类器已能取得较好效果⁹；但结合深度特征后，通常仍以端到端训练的方式，通过输出层学习分类边界。
- 多任务损失与训练：** 训练过程中，主要优化目标是熔透状态的分类损失（如交叉熵）。同时添加**主观相似度约束损失**作为辅助。具体做法可如前述方法二：对选取的样本对施加metric learning损失，或者对参考样本输出的嵌入Gram矩阵与主观矩阵计算均方差损失。总损失为 $\mathcal{L} = \mathcal{L}_{\text{class}} + \beta \mathcal{L}_{\text{metric}} + \gamma \mathcal{L}_{\text{graph}}$ （视采用的融合策略调整项数）。 β, γ 为权衡系数。通过多任务联合训练，网络参数既要服务于分类准确，又要满足感知约束。这样的训练会逐步调整深度嵌入，使其在保留判别信息的同时，对人耳敏感的差异也较为敏感。
- 推理与决策融合：** 在模型部署时，可以灵活选用融合策略。例如，为了进一步提升稳健性，可构建两个子模型：一个仅用深度CNN特征，另一个用“手工特征+MDS感知嵌入”，分别做判别，然后对两者输出结果进行加权平均融合²¹。这种后端融合可以在自动学习表征和物理解释特征之间取得平衡。如需要实时性，也可以直接使用单一融合模型进行预测。值得一提的是，如果设计了图网络模块，那么对新数据预测需考虑将其嵌入已有图的方法，可通过增量方式更新图或忽略图传播影响视具体情况权衡。

框架创新点分析： 上述框架在焊接声监测领域引入了“主观-客观融合”的新思路²²。传统方法要么仅利用客观声学信号，要么依赖焊工经验而无法自动化。而本方案首次将**焊工主观听觉评价转换为模型可用的特征与约束**，实现了经验知识的数据化利用。这种知识与数据双驱动模型具备以下创新优势：

- 提升小样本学习能力：焊接熔透数据往往难以大规模获取，引入先验知识相当于提供了额外的“虚拟样本”信息（成对关系），有助于缓解过拟合。
- 改善噪声环境鲁棒性：人耳的听觉判断往往具有抗噪性，在极端噪声下依然能捕捉熔透变化⁹。融合感知嵌入与感知约束后，模型在低信噪比条件下的表现明显提升⁹，因为主观特征在一定程度上过滤了噪声干扰。
- 提供可解释性：感知嵌入空间可以直观解释不同熔透状态之间的距离关系。例如，通过2维MDS图可以看到未熔透、完全熔透、过熔透三类样本在“人耳音色空间”的分布是否形成聚类或序列，这为结果增加了解释维度³。融合模型的一部分决策依据来源于人耳的评价尺度，因此当模型给出判定时，我们可以追溯到哪个参考声音与之相似，从而解释判定依据（这在纯深度学习黑箱模型中是困难的）。

可行性与实现要点：

- **数据获取与标定：** 主观不相似度矩阵的获取需要精心设计听觉实验。一方面要挑选具有代表性的声音样本集（涵盖各典型熔透状态及不同工况）；另一方面要控制实验变量，如收听环境、音量标准等，确保评分可靠。由于成对比较数量随样本数平方级增长，可采用部分比较加推断的方法获得矩阵。实际研究中对15条声音进行了全成对评分已取得很好效果³。未来若要扩展，可考虑主动学习选取最有信息量的样本对进行评分，以提高效率。
- **参数与模型选择：** 感知嵌入维度需基于试验确定（通常2维足够⁶）。深度网络部分可从预训练音频模型（如AudioSet的CNN模型）微调，以加速收敛。损失权重 β, γ 需要在验证集上调优，确保分类性能与感知对齐两者兼顾。
- **系统集成：** 所提框架各模块可以分步开发调试：先独立验证MDS嵌入+传统分类器效果，再融入深度CNN，最后加入度量损失/图模块观察增益。这样渐进式开发可以明确每部分贡献。最终部署时，根据实时性要求，决定是否保留复杂分支（如图传播可能不适合实时应用，则可只用训练中有图正则的模型，在推理时省去图计算）。
- **推广性：** 尽管本研究面向TIG焊接熔透状态，但该方法对**基于声音的其他工业过程监测**同样有借鉴意义。例如在机械故障诊断中，让工程师听声音找故障的经验也可用类似的不相似度方法融入模型。因此，本框架具有一定普适性，可作为**人机协同智能**的一种实现范式。

总结

综上，我们围绕焊接电弧声音的熔透状态识别，提出了融合主观不相似度知识的深度学习方案。从利用MDS构造“人耳音色”特征空间³、到以主观矩阵为依据设计度量损失¹¹，再到基于感知相似关系建立图网络约束，多个角度的研究表明：**将焊工经验融入模型能够有效提升识别性能和鲁棒性**。该知识与数据双驱动方法新颖且可行，为焊接过程的智能监测提供了一条崭新的技术路径²²。未来工作可以进一步完善人机混合建模，例如扩充主观知识库、引入更高级的注意力机制等，不断提高模型对复杂声学场景的适应能力。通过这套方法，我们有望实现比肩经验焊工甚至超越人耳的熔透状态自动识别，为焊接智能制造的质量控制贡献力量。

参考文献：

1. Ren W. J. 等, 基于电弧声时频谱图的CNN熔透状态分类¹⁷ .
2. Wu J. Z. 等, 基于电弧声音时间/频率图像的深度学习熔透识别²³ .
3. Saito Y. 等, 基于主观相似度的大规模说话人嵌入方法¹¹ .
4. 焊接声熔透主观-客观融合识别技术路线与实验分析^{1 3 6} .

- 11 [1907.08294] DNN-based Speaker Embedding Using Subjective Inter-speaker Similarity for Multi-speaker Modeling in Speech Synthesis
<https://arxiv.org/abs/1907.08294>
- 12 Comparing Class-Aware and Pairwise Loss Functions for Deep ...
<https://pmc.ncbi.nlm.nih.gov/articles/PMC8472616/>
- 13 Graph convolutional network combining node similarity association ...
<https://www.sciencedirect.com/science/article/abs/pii/S0952197623001653>
- 14 Better Inference with Graph Regularization | Guide books
<https://dl.acm.org/doi/book/10.5555/AAI28545740>
- 15 Accelerating Image Classification with Graph Convolutional Neural ...
<https://arxiv.org/html/2508.14218v1>
- 16 User similarity-based graph convolutional neural network for shilling ...
<https://link.springer.com/article/10.1007/s10489-025-06254-2>